

Lab 1: Python数据分析实践 实验报告

孙俊晖(231880101)

1 引言

1.1 背景

1912年4月14日23时40分左右，当时世界上体积最庞大、内部设施最豪华的客运轮船—泰坦尼克号与一座冰山相撞后沉没，此次沉没事故为和平时期的死伤人数最为惨重的一次海难，其残骸直至1985年才被再度发现，受到联合国教育、科学及文化组织的保护。Titanic数据集是一个关于此次沉没事故遇难者生存的数据集，包含乘客的性别、年龄、所在船舱、登船港口、票号、是否生还等信息。

1.2 目标

利用Python语言以及Python库对Titanic数据集进行读取和分析，如计算乘客的性别和年龄分布，分析不同因素对生还概率的影响等，并对此进行绘图可视化以更好的展示数据分析结果。

2 方法

2.1 技术栈

开发环境：Visual Studio Code 1.93.0

编程语言：Python 3.7.9 64-bit

2.2 数据读取、数据分析以及数据分析结果展示

2.2.1 导入所需的Python库

利用pandas库读取数据，利用matplotlib库进行绘图可视化

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
```

2.2.2 利用pandas库从titanic.csv文件中读取数据

利用pandas库读取数据后，为了便于在绘图时展示数据分析结果，将读取的数据的英文关键字替换为中文。

```

1 # 从CSV文件中读取Titanic数据集
2 data = pd.read_csv("titanic.csv", encoding="utf-8")
3 # 设置支持中文的字体
4 plt.rcParams['font.sans-serif'] = ['SimHei']
5 # 重命名列
6 data = data.rename(columns={'Survived': '结果'})
7 data = data.rename(columns={'Sex': '性别'})
8 data = data.rename(columns={'Pclass': '舱位'})
9 data = data.rename(columns={'Age': '年龄'})
10 # 重命名列中的数据
11 data['性别'] = data['性别'].replace({'female': '女性', 'male': '男性'})
12 data['结果'] = data['结果'].replace({0: '死亡', 1: '幸存'})
13 data['舱位'] = data['舱位'].replace({1: '一等舱', 2: '二等舱', 3: '三等舱'})

```

2.2.3 计算乘客性别、年龄分布

计算乘客性别分布时只需要计算男乘客和女乘客的人数即可，但计算乘客年龄分布时得先将年龄分为不同的区间，再分别计算不同年龄区间上的乘客人数。性别分布用gender_distribution表示，年龄分布用age_distribution表示。

```

1 #计算乘客性别分布
2 gender_distribution = data['性别'].value_counts()
3 #计算乘客年龄分布
4 bins = [0, 10, 20, 30, 40, 50, 60, 70, 80]
5 labels = ['0-10', '11-20', '21-30', '31-40', '41-50', '51-60', '61-70', '71+']
6 data['年龄区间'] = pd.cut(data['年龄'], bins=bins, labels=labels, right=False)
7 age_distribution = data['年龄区间'].value_counts()

```

2.2.4 分析性别、船舱和年龄对生存概率的影响

以船舱这个因素为例，先计算不同舱位等级的乘客的生还人数、死亡人数，再用（不同舱位等级的生还人数/该舱位等级的乘客总数）来刻画不同舱位的乘客的生还率。在分析性别和年龄对生存概率的影响时采用同样的方法，但在分析年龄对生存概率的影响时，与计算年龄分布时相同，分析的是不同年龄区间上乘客的生还人数与生还率。不同性别的生还人数和死亡人数用survival_by_sex表示，不同性别的生还率用survival_rate_by_sex表示；不同舱位等级的生还人数和死亡人数用survival_by_pclass表示，不同舱位等级的生还率用survival_rate_by_pclass表示；不同年龄区间的生还人数和死亡人数用survival_by_age表示，不同年龄区间的生还率用survival_rate_by_age表示；

```

1 # 分析性别对生存概率的影响
2
3 # 计算每个性别的生还人数
4 survival_by_sex = data.groupby(['性别', '结果']).size().unstack(fill_value=0)
5
6 # 计算每个性别的生还率
7 survival_rate_by_sex = survival_by_sex.div(survival_by_sex.sum(axis=1),
8 axis=0) * 100
9 # 分析船舱（舱位等级）对生存概率的影响
10 survival_by_pclass = data.groupby(['舱位', '结果']).size().unstack(fill_value=0)
11 survival_rate_by_pclass =
12 survival_by_pclass.div(survival_by_pclass.sum(axis=1), axis=0) * 100
13
14
15
16
17
18
19
20
21
22
23
24
25
26
27
28
29
30
31
32
33
34
35
36
37
38
39
40
41
42
43
44
45
46
47
48
49
50
51
52
53
54
55
56
57
58
59
60
61
62
63
64
65
66
67
68
69
70
71
72
73
74
75
76
77
78
79
80
81
82
83
84
85
86
87
88
89
90
91
92
93
94
95
96
97
98
99
100

```

```
11 #分析年龄对生存概率的影响
12 bins = [0, 12, 18, 60, 100]
13 labels = ['儿童(0-12)', '青少年(12-18)', '青年人(18-60)', '老年人(60-100)']
14 data['年龄区间'] = pd.cut(data['年龄'], bins=bins, labels=labels, right=False)
15 survival_by_age = data.groupby(['年龄区间', '结果']).size().unstack(fill_value=0)
16 survival_rate_by_age = survival_by_age.div(survival_by_age.sum(axis=1),
axis=0) * 100
```

2.2.5 展示数据分析结果

首先将计算得到的数据（性别分布、年龄分布、不同性别/舱位等级/年龄区间的生存率）直接输出

```
1 print(gender_distribution)
2 print(age_distribution)
3 print(survival_rate_by_sex)
4 print(survival_rate_by_pclass)
5 print(survival_rate_by_age)
```

输出的数据如下图所示（幸存和死亡这两列的数字表示的是幸存/死亡的乘客的百分比）：

```

男性      577
女性      314
Name: 性别, dtype: int64
21-30      220
31-40      167
11-20      102
41-50       89
0-10       62
51-60       48
61-70       19
71+         6
Name: 年龄区间, dtype: int64
结果      幸存      死亡
性别
女性  74.203822  25.796178
男性  18.890815  81.109185
结果      幸存      死亡
舱位
一等舱  62.962963  37.037037
二等舱  47.282609  52.717391
三等舱  24.236253  75.763747
结果      幸存      死亡
年龄区间
儿童(0-12)      57.352941  42.647059
青少年(12-18)   48.888889  51.111111
青年人(18-60)   38.608696  61.391304
老年人(60-100)  26.923077  73.076923

```

接着，使用matplotlib库进行绘图可视化，这里我选择采用柱状图的形式展示数据，因为柱状图易于理解，可以直观地比较不同类别的数据，并清晰地多维度展示数据的分布情况。

```

1 # 可视化性别分布
2 gender_distribution.plot(kind='bar')
3 plt.title("乘客的性别分布")
4 plt.xlabel("性别")
5 plt.ylabel("乘客数量")
6 plt.xticks(rotation=0)


```

```


7 plt.show()
8 # 可视化年龄分布
9 age_distribution.plot(kind='bar')
10 plt.title('乘客的年龄分布')
11 plt.xlabel('年龄区间')
12 plt.ylabel('乘客数量')
13 plt.xticks(rotation=0)
14 plt.show()
15 #可视化性别对生还概率的影响
16 survival_rate_by_sex.plot(kind='bar', stacked=False, figsize=(10, 6))
17 plt.title('性别对生还概率的影响')
18 plt.xlabel('性别')
19 plt.ylabel('幸存/死亡比例 (%)')
20 plt.xticks(rotation=0)
21 plt.legend(title='是否存活', labels=['幸存', '死亡'])
22 plt.show()
23 #可视化船舱对生还概率的影响
24 survival_rate_by_pclass.plot(kind='bar', stacked = False, figsize=(10, 6))
25 plt.title('船舱对生还概率的影响')
26 plt.xlabel('舱位等级(Pclass)')
27 plt.ylabel('幸存/死亡比例 (%)')
28 plt.xticks(rotation=0)
29 plt.legend(title='是否存活', labels=['幸存', '死亡'])
30 plt.show()
31 #可视化年龄对生还概率的影响
32 plt.title('年龄对生还概率的影响')
33 plt.xlabel('年龄区间')
34 plt.ylabel('生存率 (%)')
35 plt.xticks(rotation=0)
36 plt.legend(title='是否存活', labels=['幸存', '死亡'])
37 plt.show()

```


用matplotlib可视化性别分布如图所示：




用matplotlib可视化性别分布如图所示：




用matplotlib可视化性别对生还概率的影响如图所示：



用matplotlib可视化船舱对生还概率的影响如图所示：



用matplotlib可视化年龄对生还概率的影响如图所示：



3 总结

经过上述对Titanic的数据的分析后，可以从展示的数据分析结果得到以下结论：

1. 男性乘客的人数(577)明显多于女性人数(314)
2. 乘客的年龄主要集中在21-50
3. 女性乘客的生还概率(74.2%)显著高于男性乘客的生还概率(18.8%)
4. 舱位等级越高，乘客的生还概率越大(一等舱： 63.0% 二等舱： 47.3% 三等舱： 24.2%)
5. 儿童的生还概率最高(57.4%)，青少年次之(48.9%)，青年人更低(38.6%)，老年人最低(26.9%)

以下是我个人基于上述结论的一些推测：

- 1.事故发生后，泰坦尼克号上可能坚持的救援原则是先救女人和未成年人(儿童+青年人)，这才导致人数占比较低的女性乘客的生还率显著高于男性乘客，儿童和青年人的生还率显著高于青年人和老年人。
- 2.事故发生后，舱位等级越高的船舱的乘客能更及时地得到救援，这才导致舱位等级越高，乘客的生还率越大。

4 参考文献

- 1.<https://www.w3schools.com/python/default.asp>
- 2.https://blog.csdn.net/2401_85291273/article/details/139389100
- 3.https://blog.csdn.net/2201_75791084/article/details/139370223